

肺腺癌细胞表面抗原发现

基于肿瘤单细胞表达、胞外拓扑结构与正常组织治疗指数的 ADC / CAR-T 可及靶点提名。

生成日期 2026-09-16，数据来自 CZ CELLxGENE Census

2025-11-08。本报告中所有数字均从磁盘结果文件逐一读取，不凭记忆重建。

核心设计理念

本流程用“肿瘤表面特异性 × 正常组织治疗指数”而非“肿瘤必需性”来排序。抗体类疗法杀伤的是表面抗原阳性的细胞；靶点是否为肿瘤存活所必需与疗效无关，却与毒性直接相关——因为必需基因在正常组织中同样必需。因此 DepMap 基因效应值仅作注释，绝不用作筛选条件。

1. 确定搜索空间（表面基因全集）

搜索空间为 SURFY 计算表面组。主表 20,193 个蛋白中，2,886 个带表面标签，去冗余后得到 2,799 个基因：1,254 个有实验证据（CSPA 肽段捕获或 GPI 锚定），1,545 个为机器学习预测。每个基因保留其独立的拓扑结构串，因此胞外域长度与跨膜次数是逐基因解析的，而非假定。预注册验证集在此刻锁定：9/9 个已临床验证的肺腺癌抗原与 3/4 个阴性对照落在搜索空间内。

2. 获取肿瘤单细胞表达（Census）

从 CZ CELLxGENE Census 2025-11-08 按疾病标签“lung adenocarcinoma”检索原始数据。单细胞核数据会系统性低检膜蛋白转录本，故排除，共得到 831,387 个全细胞，分布于 5 个 atlas。每个 atlas 以固定种子 0 抽样至 ≤20,000 个细胞（共 82,558 个），其中 75,095 个细胞的细胞类型可映射到四个区室之一：caf 2,270、endothelial 2,544、epithelial 12,853、immune 57,428。每个基因在每个区室、每个 atlas 中的均值与表达率分别计算，再做跨数据集共识整合。

3. 胞外拓扑门控

无法在完整细胞上暴露表位的蛋白被剔除：排除 173 个基因，其中 103 个因亚细胞定位（内质网、高尔基体、内体、细胞核、胞质，或纯分泌型/细胞外基质），70 个因缺乏长度 ≥ 25 个残基的胞外片段。剩余 2,626 个抗体可及候选，每个候选均标注表面确认等级。

4. 可成药性与必需性注释

Open Targets 为 2,362 个候选提供抗体可成药性分档、独立的亚细胞定位判断与已知药物记录。表面确认等级分布：Open Targets confirmed 869；experimental (CSPA/GPI) 1,217；unconfirmed (ML prediction only) 540。DepMap 平均基因效应覆盖 18,443 个基因，仅作参考。验证靶点本身即说明原因：CD276 -0.26、CEACAM5 -0.03、EGFR -0.35、ERBB2 -0.34、FOLR1 +0.02、MET -0.12——全部远非必需基因。若以必需性做门控，恰好会剔除本流程应当重新发现的靶点，转而富集高毒性的管家基因。

5. 正常组织安全性基线（治疗指数）

安全性基线取自两套独立的 HPA 数据：共识 RNA（20,151 基因 × 51 组织）与正常组织免疫组化蛋白（15,306 基因 × 59 组织，其中 11,152 个基因通过抗体可靠性过滤）。两条通路各自给出按器官加权的风险，安全性系数取两者的保守最小值——因此一个 RNA 看似干净、却在心肌上染色的靶点仍被判为危险。140 个候选在 HPA 中无记录，采用带标记的中性默认值 0.7。队列安全性系数中位数为 0.373。

6. 复合评分与分层

最终评分取肿瘤质量、安全性系数与共识乘数三者的几何平均（即三者乘积的立方根）。这是一个单调变换：排名与直接取乘积完全一致，同时把评分放回与三个因子相同的 0–1 量纲上。肿瘤质量权重为：相对 TME 特异性 0.30、表达强度 0.20、表达均一性 0.20、胞外域可及性 0.15、抗体可成药性 0.15。安全性系数为乘性，共识乘数奖励跨

atlas 可重复性。排名前还应用了一条资格规则：候选必须在至少 10% 的上皮/恶性细胞中被检出——因为 ADC 与 CAR 无法结合大多数肿瘤细胞根本不展示的抗原。该规则搁置了 2,127 个基因（它们否则会仅凭“处处不表达”换来的高安全性系数而胜出），最终 379 个候选参与评分（另有 120 个可及基因根本不在 Census 特征集内）。按绝对阈值分层：Tier 1 共 3 个（ ≥ 0.55 ），Tier 2 共 76 个（ $0.35 - 0.55$ ），Tier 3 共 300 个。

队列构成

数据集	可用细胞数	抽样	纳入分析	供体数	测序平台
Lung cancer 4 patients archival FFPE samples profiling with Chromium FLEX	2,558	2,558	2,454	2	10x gene expression flex
The single-cell lung cancer atlas (LuCA) -- extended atlas	647,147	20,000	19,910	154	10x 3' v1, 10x 3' v2, 10x 3' v3, 10x 5' v1, BD Rhapsody Whole Transcriptome Analysis, GEXSCOPE technology, Smart-seq2, inDrop
Combined samples	57,679	20,000	20,000	21	10x 3' transcription profiling, 10x 3' v2, 10x 3' v3
An integrated cell atlas of the human lung in health and disease (full)	41,012	20,000	12,731	3	10x 3' v2
Transcriptional connectivity of regulatory T cells in the tumor microenvironment informs novel combination cancer therapy strategies	82,991	20,000	20,000	23	10x 3' v2, 10x 3' v3

7. 验证与质控

在 379 个评分候选中，预注册的已临床验证抗原的召回为recall@10 = 2/9， recall@20 = 3/9。排名最前的验证靶点是 CEACAM5，位列第 7 名。

验证靶点并未被埋没，只看召回数会产生误导。9 个中有 8 个进入排序，名次介于第 7 与第 126 名之间，中位数位于全部评分候选的前 13.7%。在肿瘤一侧它们明显优于整体：肿瘤质量中位数 0.630，队列中位数为 0.306；安全性系数同样高于队列中位数（0.131 对 0.050）。

它们没有进入前十，不是因为自身表现差，而是因为榜首的候选在正常组织中更干净：前十名的安全性系数中位数为 0.337，肿瘤质量中位数为 0.509。EGFR、HER2、TROP2、叶酸受体 α 确实在皮肤、消化道、肾与心肌中表达；它们能进入临床，靠的是可控毒性、剂量调整与患者筛选。纯表达驱动的安全性系数会如实给这份代价定价，而临床项目可以选择承受它。因此对本排序的诚实解读不是“ 没能重新发现标准疗法靶点 ”，而是它在回答另一个问题：哪些抗原的正常组织谱优于已进入临床的靶点。若把排序反复调到已知答案重新回到前列，那只是对着自己的验证集调参。

完全未进入排序的靶点：ROR1（仅在 4.6% 的上皮细胞中检出，低于 10% 的抗原展示阈值）。

预注册验证靶点

基因	排名	分位	评分	肿瘤质量	安全性	风险最高的正常组织	备注
CEACAM5	7	前 1.6%	0.528	0.701	0.300	Colon	
MSLN	9	前 2.1%	0.515	0.777	0.175	Colon	
EGFR	15	前 3.7%	0.500	0.498	0.279	Kidney	
CD276	45	前 11.6%	0.389	0.315	0.373	Liver	
ERBB2	59	前 15.3%	0.369	0.585	0.086	Heart muscle	
FOLR1	98	前 25.6%	0.329	0.710	0.050	HPA 无记录	
TACSTD2	107	前 28.0%	0.323	0.676	0.050	Kidney	
MET	126	前 33.0%	0.307	0.577	0.050	Cerebral cortex	
ROR1	-	-	n/a	n/a	n/a	HPA 无记录	仅在 4.6% 的上皮细胞中检出，低于 10% 的抗原展示阈值

阴性对照：EPCAM PASS（排名 83/379）；CDH1 PASS（排名 99/379）；ATP1A1 PASS（排名 238/379）；CGN PASS（从未进入搜索空间（SURFY 判定为非表面蛋白））。总体判定：PASS。

在 6 组安全性聚合与加权替代方案下的排名稳定性：与基线排序的 Spearman 相关系数中位数为 0.870，最差的前 20 名重叠为 8/20。因此排序前列并非某一组特定参数化的产物。

替代方案	与基线的 Spearman 相关	前 20 名重叠	Tier 1 数量
安全性取蛋白与 RNA 两臂的均值（而非保守最小值）	0.801	15/20	9
安全性仅取免疫组化蛋白一臂	0.658	8/20	33
安全性仅取共识 RNA 一臂	0.687	13/20	6
安全性以平方根进入：更温和的毒性惩罚	0.940	17/20	31
五个肿瘤质量子项等权 0.20	0.996	18/20	4
特异性权重 0.50，其余四项各 0.125	0.992	20/20	7

候选靶点提名

对前 12 名候选逐一用固定查询式检索 Europe PMC，分别覆盖适应症生物学、表面靶向模态与临床阶段。证据分级分布：有临床前表面靶向证据（6）；已临床验证的靶点（4）；全新——无表面靶向文献（1）；仅有肿瘤生物学证据（1）。


#	基因	评分	分层	特异性	安全性	拓扑结构	表面确认等级	证据分级
1	LY6K	0.633	Tier 1	0.77	0.60	GPI / no TM	实验确认	有临床前表面靶向证据
2	ITGB6	0.555	Tier 1	1.00	0.24	type I	Open Targets 确认	已临床验证的靶点
3	CDCP1	0.551	Tier 1	0.45	0.37	type I	实验确认	有临床前表面靶向证据
4	IGSF3	0.548	Tier 2	0.55	0.49	type I	仅 ML 预测	全新——无表面靶向文献
5	SLC6A14	0.543	Tier 2	0.78	0.46	multi-pass (12 TM)	Open Targets 确认	仅有肿瘤生物学证据
6	CRB3	0.531	Tier 2	0.97	0.28	type I	Open Targets 确认	有临床前表面靶向证据
7	CEACAM5	0.528	Tier 2	1.00	0.30	GPI / no TM	实验确认	已临床验证的靶点
8	CDH3	0.523	Tier 2	0.52	0.37	type I	实验确认	已临床验证的靶点
9	MSLN	0.515	Tier 2	1.00	0.18	GPI / no TM	实验确认	已临床验证的靶点
10	MUC4	0.512	Tier 2	0.82	0.30	type I	实验确认	有临床前表面靶向证据
11	CELSR1	0.506	Tier 2	0.41	0.36	multi-pass (7 TM)	实验确认	有临床前表面靶向证据
12	EFNA4	0.504	Tier 2	0.24	0.55	GPI / no TM	实验确认	有临床前表面靶向证据

文献证据分级


基因	证据	适应症文献数	模态文献数	Open Targets 已知药物
LY6K	有临床前表面靶向证据	19	10	-
ITGB6	已临床验证的靶点	30	21	ABITUZUMAB; STX-100; SIGVOTATUG VEDOTIN ...
CDCP1	有临床前表面靶向证据	67	70	-
IGSF3	全新——无表面靶向文献	5	2	-
SLC6A14	仅有肿瘤生物学证据	12	1	-
CRB3	有临床前表面靶向证据	5	11	-
CEACAM5	已临床验证的靶点	111	147	ARCITUMOMAB; LABETUZUMAB ...
CDH3	已临床验证的靶点	42	22	PF-03732010
MSLN	已临床验证的靶点	100	295	SS1(DSFV)-PE38; ANETUMAB RAVTANSINE ...
MUC4	有临床前表面靶向证据	102	157	-
CELSR1	有临床前表面靶向证据	5	5	-
EFNA4	有临床前表面靶向证据	12	9	-

图表


共生成 4 幅图 (PNG + SVG)。导出包通过了 8/8 项一致性门控，逐项交叉核对队列细胞数与表达矩阵、报告中的召回字符串与逐基因排名、阴性对照判定与判定规则、文献表与排序表。




Compartment expression of the top candidates
cross-atlas consensus, counts per 10,000 per cell



Therapeutic index: tumour profile against normal-tissue risk





导出一致性门控

一致性门控	结果	细节
队列细胞数核对	PASS	75,095 cells summed over compartments = 75,095 in the cohort table = 75,095 in provenance
抽样上限	PASS	max sampled per atlas 20,000 <= ceiling 20,000
表达矩阵覆盖度	PASS	2,674/2,674 genes carry statistics from all 5 atlases
排序完整性	PASS	379 unique genes, scores monotone in [0,1], range 0.151-0.633
召回报告规范	PASS	@10: reported 2/9, recomputed 2/9; @20: reported 3/9, recomputed 3/9
阴性对照判定	PASS	EPCAM=PASS(rank 83); CDH1=PASS(rank 99); ATP1A1=PASS(rank 238); CGN=PASS(rank -)
文献表覆盖	PASS	12 reviewed candidates match ranks 1-12
图件齐备	PASS	8 files (4 figures x PNG+SVG)

局限性

- 转录本丰度只是表面蛋白密度的替代指标；ADC 真正需要的是每个细胞的蛋白拷贝数，RNA 可能高估也可能低估。
- 区室划分依赖各 atlas 提供的 Cell Ontology 标签；恶性细胞未经拷贝数重新判定，因此上皮区室混合了恶性与正常上皮。
- HPA 免疫组化依赖抗体且为半定量；抗体缺失或信号弱会被误读为“安全”。
- 安全性模型按“抗原阳性杀伤在该器官的可耐受程度”给器官加权。这些权重是明示的判断，不是测量值。
- 文献分级中的“全新”指没有被索引到的表面靶向文献，并不等于没有在先技术。

数据来源

SURFY surfaceome: https://wollscheidlab.org/SURFY/table_S3_surfaceome.xlsx

CZ CELLxGENE Census 2025-11-08

Human Protein Atlas consensus RNA: https://www.proteinatlas.org/download/tsv/rna_tissue_consensus.tsv.zip

Human Protein Atlas normal-tissue IHC: https://www.proteinatlas.org/download/tsv/normal_ihc_data.tsv.zip

Open Targets Platform GraphQL: <https://api.platform.opentargets.org/api/v4/graphql>

DepMap CRISPR gene effect: <https://ndownloader.figshare.com/files/43346616>
Europe PMC: <https://www.ebi.ac.uk/europepmc/webservices/rest/search>