

GSK3 β 从头小分子设计报告

[品牌标识位]
logo / 字标

靶点：糖原合成酶激酶-3 β (GSK3B, UniProt P49841, ChEMBL CHEMBL262)

生成日期 2026-10-03 | 图遗传算法 | 共评估 8,175 个分子 | 最终入选 10 个设计

8,175

生成并打分的
去重分子总数

7,170

合法且通过
性质门

248

通过完整
筛选级联

10

最终入选
(互不相同的骨架类型)

7/10

获得可行
逆合成路线

本报告是什么。十个由算法从头生成的分子，依据代理活性模型结合类药性与合成可及性启发式指标排序。**这些化合物均未经合成，也未做任何实验测定。**报告中出现的每一个活性数值都是模型预测值而非实测值，而该模型恰恰就是生成算法所优化的对象——在依据任何排序做决策之前，请先阅读「局限性」一节。

1. 引言

GSK3B 是一种组成型激活的丝氨酸/苏氨酸激酶，位于 Wnt/ β -catenin 通路、胰岛素信号通路与微管调控的交汇点。它的失调与阿尔茨海默病的几项核心病理特征直接相关——磷酸化 tau 蛋白、调节 β -淀粉样蛋白生成、影响神经发生与突触功能——因此长期以来是中枢神经系统领域被反复开发的重要靶点[6]。这一历史对设计工作而言是双刃剑：靶点验证充分、数据注释丰富，数据驱动的生成模型有足够的学习素材；但围绕它的可及化学空间也早已被药物化学家充分开垦，真正新颖的骨架类型相应地更难触及。

本项目要回答的是一个范围明确、可操作的问题：以已知的高活性 GSK3B 结合分子为起点，图遗传算法能否产生同时满足以下三点的分子——(a) 在预训练的 GSK3B 活性代理模型上得分良好；(b) 具备类药性且合成上可行；(c) 在结构上与起点分子有实质区别？交付物是一份含性质、新颖性度量、结构警示与逆合成路线的十分子候选清单，供药物化学家做初步分诊之用，而非一组结论。

2. 方法

2.1 参考数据与种子分子

已知活性分子通过 ChEMBL REST API 获取（版本 [ChEMBL_37](#)，检索日期 2026-10-03），靶点 CHEMBL262，限定为 IC₅₀/K_i/K_d 类型且 pChEMBL ≥ 7 的记录（即活性优于 100 nM）。共返回 2,195 条活性记录，对应 **1,830 个去重化合物**，每个化合物取其最高活性记录。该集合承担两个彼此独立的角色：遗传算法初始种群的来源，以及后续衡量新颖性的参照系。初始种群取其中结构差异最大的 200 个分子，由 Morgan 指纹上的 MaxMin 算法挑选，以避免算法一开始就落在单一骨架类型内部。

2.2 分子生成

分子由直接作用于分子图的图遗传算法生成，算子族遵循 Jensen [1] 与 GuacaMol 的 graph-GA 基线 [2]，本次基于 RDKit 自行实现，未沿用上述任一代码库。交叉操作在两个亲本的随机非环单键处断裂，各取一个片段重新连接；变异操作每次施加一种局部图编辑：原子追加（取自常见药物化学环系与取代基库）、元素替换、端位原子删除、键级改变、或在键中插入原子。每个子代都经过净化并通过 SMILES 往返校验，凡 RDKit 无法解析者一律丢弃。选择策略为精英截断，亲本按排名加权采样。参数：种群 200，迭代 40 代，每代产生 200 个子代，变异率 0.5，随机种子 42。CPU 实际运行时间 229 秒。

2.3 目标函数

每个分子的得分为三项归一化指标的几何平均：GSK3B 代理活性、QED 类药性 [3]，以及合成可及性项 (10 SA_Score)/9 [4]。采用几何平均是刻意的合取式设计：任一项为零则总分为零，算法无法通过牺牲类药性来换取更高的预测活性。活性项采用 Therapeutics Data Commons [8] 发布的预训练 GSK3B 代理模型——一个基于 ECFP 特征的随机森林，输出值域 [0,1]。此外设置硬性门控，将落在以下范围之外的分子直接归零：分子量 150–600、重原子数 10–50、 $\text{cLogP} \leq 6$ 、 $\text{SA_Score} \leq 6$ 、形式电荷为零、单一片段、无大于七元的环，元素限定为 C/N/O/S/F/Cl/Br。若无此门控，优化代理模型的遗传算法必然会漂移到得分虚高但根本无法合成的化学空间中去。

2.4 筛选与遴选

候选池取自运行过程中出现过的全部分子，而非仅最终种群。级联筛选依次为：合法性、去重与门控存活；新颖性（对全部参考活性分子的最大 Tanimoto < 0.40 ，Morgan 半径 2、2048 位）；活性 ≥ 0.50 且 QED ≥ 0.60 ；不含 PAINS A/B/C 子结构 [5]；环系合理性； $\text{SA_Score} \leq 4.5$ 。直接取得分最高的十个分子，结果是同一母核的十种修饰，因此最终遴选改为：对存活分子做聚类（Butina，Tanimoto 0.4），从得分最高的十个簇中各取最优代表。此前曾尝试以 Bemis-Murcko 骨架唯一性作为判据并予以否决——更换一个侧挂环即可改变 Murcko 骨架，而分子识别基元丝毫未变，该判据过于宽松。

2.5 逆合成与结构警示

逆合成路线由 AiZynthFinder [7] 给出，使用公开的 USPTO 模板库、扩展与过滤策略以及 ZINC 可购库存，每个分子的搜索预算为 120 秒。此外对入选分子做了 Brenk 活性/不宜基团警示与迈克尔受体 SMARTS 的显式比对；这些结果以标注形式记录而非用作筛选条件，原因是若干已验证的 GSK3B 骨架类型本身即为马来酰亚胺。

3. 结果

3.1 收敛情况

算法收敛平稳。40 代中，种群平均分从 0.662 升至 0.851，最优个体从 0.874 升至 0.895；在同时满足 Tanimoto < 0.4 新颖性判据的分子中，最优分从 0.633 升至 0.856。最优分曲线呈阶梯状，这是精英截断策略的预期表现。平均分曲线在约第 25 代后趋平，说明种群已基本收敛；未继续延长迭代，因为后续世代产生的多是已有骨架类型的修饰，而非新的骨架。




图 1. 各代目标函数得分。「新颖分子最优」曲线始终低于不受约束的最优值，这正是本项目的核心张力：代理模型奖励与已知活性分子的相似性，而新颖性判据恰恰惩罚这种相似性。

3.2 筛选衰减

在 8,175 个去重分子中，7,170 个合法、去重且落在性质门之内。新颖性是迄今最严苛的一道筛选，剔除了 4,566 个分子（占进入该阶段分子的 64%）——算法的大部分努力都花在了起点附近。活性与 QED 联合门控又剔除 2,340 个。PAINS、环系合理性与合成可及性三项合计仅剔除 16 个，这与其说反映了设计分子质量优良，不如说是因为性质门已经提前排除了这些筛选所针对的大部分情形。最终 248 个分子通过完整级联。




图 2. 按图示顺序施加各级筛选后的剩余分子数。

3.3 新颖性

此处的新颖性是一个可量化的指标，而测量结果并不乐观。在全部生成分子中，与最近已知活性分子的相似度众数约在 0.45–0.50。在通过级联的 248 个分子中，分布被紧紧压在 0.40 这条界线之下：154 个落在 0.35–0.40 之间，69 个落在 0.30–0.35，25 个落在 0.20–0.30，**0.20 以下一个也没有**。最终入选的十个设计相似度区间为 0.36–0.40。因此这些分子的「新颖」仅在方法一节所定义的、相对于特定阈值的意义上成立。它们不是新的骨架类型，而是一片已被充分开垦的区域边缘上的新坐标点。换一个阈值就会得到另一套答案，而这种敏感性本身就是结论的一部分。

生成分子与最近已知活性分子的相似度分布




图 3. 每个生成分子与 1,830 个参考活性分子中最近者的最大 Tanimoto 相似度。位于 1.0 处的尖峰是种子分子本身，它们原本就是已知活性分子。

3.4 理化性质

存活的设计分子系统性地比其所源自的已知活性分子更小、极性更低——生成分子的分子量分布集中在 250–350 Da，而 ChEMBL 集合约在 350–450 Da，TPSA 也相应更低。这是含 QED 项的打分函数的已知偏倚：QED 在各性质区间的中段取得峰值，而非在许多经优化的激酶抑制剂所处的上段。合成可及性与参考集合重合良好。其实际含义是：这些设计分子在后续优化中还有向上生长的余量，对一个起点而言，这个位置是合理的。

理化性质分布：设计分子 vs 已知活性分子





图 4. 通过级联的设计分子（填充）与随机抽取的 400 个 ChEMBL 参考活性分子（描边）的性质分布对比。

3.5 入选设计


十个设计分别取自得分最高的十个骨架类型簇（存活分子共聚为 85 簇）的最优代表。相较于直接取前十名，骨架感知的遴选方式在平均目标标上付出了约 0.03 的代价（0.804 对 0.841），换来的是一组识别基元明显不同的候选组合，而不是同一个方案的十种写法。

编号	总分	活性	QED	SA	相似度	分子量	cLogP	TPSA	路线	结构警示
DN-01	0.856	0.88	0.81	2.04	0.39	306	3.4	35	1 步	—
DN-02	0.828	0.84	0.83	2.67	0.39	296	1.1	78	未解出	马来酰亚胺、迈克尔受体
DN-03	0.810	0.70	0.88	2.25	0.40	288	2.3	70	3 步	马来酰亚胺、迈克尔受体、腈基
DN-04	0.804	0.88	0.73	2.76	0.38	388	0.3	114	2 步	马来酰亚胺、迈克尔受体、磺酰胺
DN-05	0.796	0.80	0.77	2.65	0.37	311	0.2	81	4 步	马来酰亚胺、迈克尔受体
DN-06	0.796	0.78	0.80	2.68	0.36	278	3.1	75	未解出	腈基
DN-07	0.793	0.72	0.91	3.15	0.39	322	1.2	97	未解出	噻吩二酮、迈克尔受体
DN-08	0.792	0.81	0.70	2.09	0.36	328	4.9	62	1 步	腈基
DN-09	0.786	0.64	0.87	2.18	0.38	269	2.7	53	2 步	—
DN-10	0.778	0.86	0.67	2.66	0.39	387	1.8	81	6 步	马来酰亚胺、迈克尔受体


表 1. 入选设计一览。「活性」为 GSK3B 代理模型输出；「相似度」为对任一参考活性分子的最大 Tanimoto；「路线」为 120 秒预算内 AiZynthFinder 找到的最短路线。各分子结构见图 5，完整 SMILES、骨架与最近邻参考分子见随附的 CSV 文件。




GSK3B-DN-01




GSK3B-DN-02




GSK3B-DN-03




GSK3B-DN-04




GSK3B-DN-05




GSK3B-DN-06




GSK3B-DN-07



GSK3B-DN-08



GSK3B-DN-09



GSK3B-DN-10

图 5. 十个入选设计，每个骨架类型簇一个代表。对应的得分、性质与结构警示见表 1；它们都是代理模型输出与启发式指标，并非实测值。

3.6 逆合成

AiZynthFinder 为十个设计中的 7 个返回了至少一条完全解出的路线（所有叶节点均在 ZINC 库存中），最短路线为 1–6 步。其中若干提议在化学上相当常规、表面看来可行——DN-01 归结为芳基硼酸与溴代吡啶的 Suzuki 偶联，DN-08 归结为甲硫基嘧啶与苯胺之间的芳香亲核取代。未解出的三例（DN-02、DN-06、DN-07）返回的是部分路线树，其叶节点未能在预算内全部落到可购试剂上；这说明的是模板库覆盖范围与搜索预算的限制，并不能证明这些分子不可合成。所有路线均为基于模板的提议，不包含任何关于收率、选择性或保护基策略的信息。

4. 结论

流程已完整跑通，且成本极低。共生成 8,175 个分子，完成三目标打分、筛选、聚类与逆合成，CPU 耗时不足 6 分钟，随机种子固定，结果可复现。

优化成功了，新颖性在很大程度上没有。目标函数提升显著，设计分子具备类药性且合成可行。但没有任何一个存活分子与已知活性分子的相似度低于 0.20，且存活分子紧贴 0.40 这条界线堆积。诚实的解读是：算法重新发现并重组了已有的 GSK3B 药效团家族——马来酰亚胺、苯胺基嘧啶、氮杂吡啶、吡啶——而不是创造了新的家族。

这种「重新发现」本身是一个弱阳性对照。一个优化 GSK3B 代理模型的生成器，最终收敛到真实 GSK3B 项目同样收敛到的骨架类型上，这说明代理模型确实捕捉到了某些真实信息。但它不能作为这些具体分子具有活性的证据。

骨架坍塌是默认结果，必须主动设计对策。朴素的前十名是同一母核的十种修饰。只有显式聚类才产生了真正的候选组合。任何不带多样性判据就报告 top-N 清单的设计项目，很可能是把同一个赌注报告了 N 遍。

5. 局限性

以下局限并非例行免责声明；其中数条会实质性影响上述排序该如何被解读。

活性评分是代理模型，而生成算法正是直接针对它做优化的。这是最主要的一条。GSK3B 代理模型是在公开数据上训练的、基于指纹的随机森林；遗传算法以数千次查询去搜索它，必然会找到部分因模型假象而得分偏高的输入。代理模型输出高，只能说明该分子与模型训练集中的活性分子相似，不能说明它会结合靶点。本次未做任何分子对接、自由能计算或结构验证。

新颖性是相对于阈值的，且相当勉强。0.40 这个 Tanimoto 阈值是一个约定，而非化学本身的性质。存活分子集中在 0.35–0.40，因此阈值、指纹类型或半径的小幅改动，都会显著改变哪些分子算作「新颖」。

十个设计中六个带有结构警示，其中五个是马来酰亚胺。马来酰亚胺以及 DN-07 中的噻吩二酮都是迈克尔受体，存在共价反应性与广谱干扰的风险。PAINS 过滤并不能识别它们。保留它们是因为已验证的 GSK3B 抑制剂（SB-216763、双吡啶基马来酰亚胺）本身就含这一基元——但一份以马来酰亚胺为主的候选清单是实实在在的风险，而非中性的观察结果；DN-01、DN-06、DN-08、DN-09 是其中不带警示的四个。

QED 与 SA_Score 都是启发式指标。QED 编码的是一种聚合的类药性观念，会惩罚那些在经优化的激酶抑制剂中常见的较大、极性较强的分子，这一点在图 4 中清晰可见。SA_Score 是基于片段频率的替代指标，系统性地偏袒由常见片段拼搭而成的分子——而这恰恰就是本生成器所构造的那类分子。

逆合成路线是 USPTO 模板给出的提议。路线「解出」只意味着搜索触及了可购买的叶节点，不蕴含任何关于收率、选择性、规模或保护基的信息，且模板库反映的是历史上已发表的反应。

单次运行，单一随机种子。仅在种子 42 下运行了一次遗传算法，没有重复实验，因此结果的方差未经测量。这十个具体分子应被视为某个分布中的一次抽样，而非最优解。

完全未评估选择性。GSK3A 与 GSK3B 的 ATP 位点结构几乎完全一致，而本流程没有涉及任何激酶组范围的选择性、细胞活性、膜通透性、血脑屏障穿透或毒性评估。

6. 后续工作建议

打破代理模型的主导。用算法从未见过的正交方法重新给 248 个存活分子打分——对 GSK3B 的 ATP 位点结构（可用结构不少，如 1Q5K、6B8J），或采用共折叠模型——只保留两种方法都认可的分子。在没有实验的条件下，两种方法之间的分歧是信息量最大的信号。

做重复实验并报告方差。跑 5–10 个随机种子，然后统计每个骨架类型复现的频率。跨种子稳定出现的骨架，价值高于单次运行中的最高分。

把新颖性放进目标函数，而不只是放在筛选里。加入显式的新颖性或多样性奖励，可以让算法主动用预测活性去交换真正的结构突破，而不是在事后被筛掉——后者正是造成分子在阈值处堆积的原因。

就马来酰亚胺做明确的取舍。在项目层面决定共价/反应性骨架是否在范围之内。若不在，可在门控中加入迈克尔受体排除项重跑；不带警示的四个设计（DN-01、DN-06、DN-08、DN-09）说明本流程有能力产出这类分子。

补充 GSK3A 反向筛选与 ADMET 评估，再做任何合成决策，并请药物化学家复核所提议的路线——模板上成立不等于一份合成方案。

7. 参考文献

- [1] Jensen JH. A graph-based genetic algorithm and generative model/Monte Carlo tree search for the exploration of chemical space. *Chem Sci* 2019;10(12):3567-3572. doi:10.1039/c8sc05372c
- [2] Brown N, Fiscato M, Segler MHS, Vaucher AC. GuacaMol: Benchmarking Models for de Novo Molecular Design. *J Chem Inf Model* 2019;59(3):1096-1108. doi:10.1021/acs.jcim.8b00839
- [3] Bickerton GR, Paolini GV, Besnard J, Muresan S, Hopkins AL. Quantifying the chemical beauty of drugs. *Nat Chem* 2012;4(2):90-98. doi:10.1038/nchem.1243
- [4] Ertl P, Schuffenhauer A. Estimation of synthetic accessibility score of drug-like molecules based on molecular complexity and fragment contributions. *J Cheminform* 2009;1(1):8. doi:10.1186/1758-2946-1-8
- [5] Baell JB, Holloway GA. New substructure filters for removal of pan assay interference compounds (PAINS) from screening libraries and for their exclusion in bioassays. *J Med Chem* 2010;53(7):2719-2740. doi:10.1021/jm901137j
- [6] Lauretti E, Dincer O, Praticò D. Glycogen synthase kinase-3 signaling in Alzheimer's disease. *Biochim Biophys Acta Mol Cell Res* 2020;1867(5):118664. doi:10.1016/j.bbamcr.2020.118664
- [7] Genheden S, Thakkar A, Chadimová V, Reymond JL, Engkvist O, Bjerrum E. AiZynthFinder: a fast, robust and flexible open-source software for retrosynthetic planning. *J Cheminform* 2020;12(1):70. doi:10.1186/s13321-020-00472-1
- [8] Huang K, Fu T, Gao W, et al. Therapeutics Data Commons: machine learning datasets and tasks for drug discovery and development. *tdcommons.ai* (软件与预训练 GSK3B 代理模型, 访问日期 2026-10-03)。
- [9] ChEMBL 数据库, 版本 ChEMBL_37, EMBL-EBI. 靶点 CHEMBL262 的活性数据于 2026-10-03 经 ChEMBL REST API 获取。
ebi.ac.uk/chembl
- [10] RDKit : 开源化学信息学工具包。rdkit.org

文献 [1]–[7] 经 PubMed 检索核对, 生物活性数据来自 ChEMBL。全部十个设计分子均为计算提议, 未经合成, 也未做任何实验测定。