

测序数据核查报告

样品 37HVPX_1_D12 · 双价 VHH CAR 慢病毒载体

项目	内容
文件名	37HVPX_1_D12.ab1
文件格式	ABIF (.ab1) —— 但只有 10 个标签，仅够查看器打开的最小集
仪器元数据	完全没有（无机型、染料、泳道、日期、运行方法）
原始道 DATA1-4	不存在
读长	4580 bp（毛细管电泳物理上限约 1000–1200 bp）
质量值	Q4–50，均值 10.6，中位数 10，众数 9
内容	HIV-1 慢病毒转移载体表达盒 + 二代双价 VHH CAR

结论一：不是 Sanger，也不是纳米孔的原始读段。

4580 bp 远超毛细管电泳上限；但文件声称 Q9–12（≈10% 错误率），而序列在有公共参考的地方几乎零错误。质量值和序列互相矛盾。

结论二：这份文件比案例 1 干净得多，性质不同。

没有伪造仪器元数据，没有他人样品的原始道，色谱图是透明的方波渲染（峰高 = $19.7 \times QV$ ， $r = 0.9965$ ）。这像一次诚实的格式转换（FASTQ / FASTA → .ab1 供 SnapGene 查看），可疑的只有那条质量串。

结论三：序列内容本身合理，但无法自证。

完整的二代 BB₇ 双价 VHH CAR 表达盒，1488 nt
阅读框无移码、无提前终止，元件齐全、边界准确。作为一张图纸没问题；但它证明不了手上的质粒真的长这样。

本报告结构

一	这是什么文件：与案例 1 对比 + 色谱图渲染证据
二	质量值与序列对不上：滑窗一致性 + 两条判据
三	一处确实像纳米孔：3' 端 36 bp 折返
四	序列内容：载体图谱、CAR 结构域、VHH 特征
五	能不能用 + 该要什么数据

一、这是什么文件

文件头 4 字节仍是 ABIF，但内部与案例 1 的那份伪造 Sanger 谱图完全不是一回事：

	案例 1 DAPA21	案例 2 37HVPX_1_D12
ABIF 标签数	126	10 (最小集)
仪器元数据	完整伪造：3730xl / POP7 / BigDye v3 / 泳道 / 日期	完全没有
原始道 DATA1-4	有，但属于另一份 2023 年的哺乳载体样品	没有
读长	735 bp	4580 bp
质量值	全部恒为 50	Q4-50，均值 10.6
色谱图	等高等宽高斯，伪装成真实电泳	方波渲染，4 采样点/碱基，峰高 = $19.7 \times QV$
性质判断	伪造的 Sanger 谱图	诚实的格式转换




图 1 ① 每个碱基固定占 4 个采样点，波形是方波而非电泳峰。② 把每个碱基的峰高对它的质量值作图，落在一条直线上（峰高 $\approx 19.7 \times QV + 14$ ， $r = 0.9965$ ）—— 色谱图是直接由质量串画出来的，不含任何独立的测量信息。

二、质量值与序列对不上

沿读段每 500 bp 取一个窗口，把「质量值隐含的错误率」与「实测同公共参考的不一致率」并排比较：




图 2 黄色区间是自定义 VHH / CAR 序列，公共库里没有确切参考，低一致性只说明「查不到」，不代表测序错误。区间之外的每个窗口，实测一致性都是 99–100%。

读段窗口	平均 QV	QV 隐含错误率	BLAST 最佳一致性	最佳命中
1–500	16.4	5.0%	464/464 = 100%	合成构建体
501–1000	10.2	9.6%	267/311 = 86%	CAR 构建体（自定义区）
1001–1500	9.8	10.6%	271/345 = 79%	CAR 构建体（自定义区）
1501–2000	9.1	12.5%	180/229 = 79%	双峰驼免疫球蛋白 mRNA
2001–2500	9.0	12.5%	287/291 = 99%	载体 pGZ-DSB-SDSA
2501–3000	9.0	12.5%	500/500 = 100%	人基因组序列
3001–3500	9.8	10.6%	500/500 = 100%	载体 pGA1backbone
3501–4000	10.5	9.0%	439/440 = 99%	载体 pLVX.TRE3G
4001–4500	11.2	7.6%	500/500 = 100%	合成构建体

两条判据

- 三个独立的 500 bp 窗口对公共参考 500/500 全对。若真是 Q10（10% 每碱基错误率），单个 500 bp 窗口完全无误的概率约 $0.9^{500} \sim 1e-23$ ，三个窗口同时如此更无可能。
- 1488 nt 的 CAR 阅读框译出 495 aa，无移码、无提前终止，结构域边界完全正确。纳米孔的错误以插入缺失为主，Q10 的原始读段会把这么长的阅读框打得千疮百孔。

所以：这条序列是打磨过的（consensus / 组装 / 或设计图），那条 Q9–12 的质量串不是它的质量。

三、一处确实像纳米孔

读段 3' 末端有 36 bp 折返：在回文位点 CAGCTG 处掉头，接着读回前面序列的反向互补。

载体正义方向最后 60 bp（竖线为掉头处）：

```
...GACCAATGACTTACAAGGCAGCTG | CCTTGTAAGTCATTGGTCCCTCATATCTCCTCCTCC
                                = revcomp(GGAGGAGGAGATATGAGGGACCAATGACTTACAAGG)
```

这是纳米孔建库时双链未分开、测完一条链折回去测互补链的典型假象。所以底层数据很可能确实是纳米孔的——但这份 .ab1 是成品，不是证据。

四、序列内容：二代双价 VHH CAR 慢病毒转移载体

以下坐标为载体正义方向（即文件内序列的反向互补），全长 4580 bp。



图 3 上：慢病毒转移载体表达盒，从 RRE 一直读到 3'ΔU3 LTR 起始，完整覆盖整个「有效载荷」区。下：CAR 的结构域组成。

位置	元件
1 .. ~850	HIV-1 env 片段 / RRE (Rev 应答元件, 茎环 136–171)
861 .. 899	cPPT / CTS (中央多聚嘌呤序列)
1176 .. ~2350	人 EF-1α 启动子 (完整, 含内含子; 供体 1400, 受体 2341)
2358 .. 2401	多克隆位点 NheI–AgeI–BglII–XhoI–SacI–HindIII–EcoRI
2402 .. 2416	Kozak GCCGCCACC + 起始密码子
2411 .. 3898	CAR 阅读框, 1488 nt / 495 aa
3890 .. 3904	终止密码子 TAA + XbaI
3919 .. ~4500	WPRe (土拨鼠肝炎病毒转录后调控元件)
4510 .. 4544	3'ΔU3 LTR 起始
4545 .. 4580	折返假象 (36 bp)

CAR 结构域

氨基酸位置	结构域	说明
1 – 21	CD8α 信号肽	MALPVTALLPLALLHAARP
22 – 142	VHH1	骆驼科单域抗体
143 – 147	(G ₄ S) 连接子	串联双价
148 – 260	VHH2	骆驼科单域抗体
273 – 317	CD8α 铰链	TTTPAPRPPTAPTASQPLSLRPEACRPAAGGAVHTRGLDFACD
318 – 341	CD8α 跨膜	IYIWAPLAGTCGVLLSLVITLYC
342 – 383	4-1BB (CD137) 共刺激域	KRGRKKLLYIFKQPFMRPVQTTQEEDGCSCRFEEEEGGCEL
384 – 495	CD3ζ 信号域	RVKFSRSADAPAYQQGNQLYNELNLGRR...

即标准的二代 BBζ CAR。共刺激域是 4-1BB 而非 CD28 (CD28 的胞内段 RSKRSRLHSDYMNMTPRRPGPTRKHYQPYAPPRDFAAYRS 未出现)。

两个 VHH 的骆驼科特征

	VHH1 (aa 22–142)	VHH2 (aa 148–260)
FR2 hallmark	WYRQ	WGRQ
CDR1	RYTSSGCNVG (含 Cys)	GFAFSNYAMS
CDR3	NIAPPYTTHCASRRF (含 Cys)	AENVDCYGGYCYRANY (含 2 个 Cys)
额外二硫键	CDR1 – CDR3	CDR3 内部

常规抗体重链 FR2 此处是 WVRQ；两个结构域都带 VHH 特有的替换，并各有一对额外二硫键——是真正的纳米抗体，不是 scFv。

blastp 查不到确切来源：最好的命中是各种羊驼纳米抗体，只有 70–75% 一致。属于自有 / 未公开的 VHH，从序列判断不出靶点。

五、能不能用

序列内容本身合理。阅读框干净、元件齐全、结构域边界准确、Kozak 正确 —— 作为一张图纸没问题。但它不能自证。序列是打磨过的、质量串叉和序列对不上，这份 .ab1 证明不了手上的质粒真的长这样。

若对方做的是纳米孔全质粒测序（常见服务），完整交付应包含：

1	原始 reads —— FASTQ（或 POD5 / FAST5）
2	比对结果 —— BAM + 覆盖深度曲线
3	组装 / consensus FASTA + 组装工具与版本
4	CAR 插入片段（2411–3898）上的覆盖深度，以及有没有 reads 完整跨过整个插入片段

有了第 2 和第 4 项才谈得上「验证」；现在这份只是把结论渲染成了一张图。

附录 A 方法

步骤	做法
解析	Biopython SeqIO("abi") 读取 ABIF 标签；直接比对 PLOC 间距、DATA9-12 长度与碱基数
渲染判定	取每个碱基在 PLOC 处的峰高，与 PCON 的质量值做线性回归
滑窗一致性	沿读段每 500 bp 取一段，各自提交 NCBI BLAST (blastn 对 nt)
折返检验	读段与自身反向互补做局部比对 (Biopython PairwiseAligner)
阅读框	定位 Kozak + ATG 后翻译至终止密码子，比对已知结构域基序
VHH 溯源	两个可变域分别提交 blastp 对 nr

依赖：biopython · numpy · matplotlib · reportlab；BLAST 经 NCBI URL API。序列同源判定依赖 NCBI 公共数据库 2026-08 版本。

附录 B CAR 蛋白序列（495 aa）

1	MALPVTALLL PLALLLHAAR PEVQLVESGG GLVQPGGSLR LSCAASRYTS SGCNVGWYRQ
61	APGKERELVS SIFSDGRPFY ADSVKGRFTI SRDNSKNTLY LQMNSLRAED TAVYYCNIAP
121	PYTTHCASRR FWGQGTLVTV SSGGGGSEVQ LVESGGGLVQ PGGSLRLSCA ASGFAFSNYA
181	MSWGRQAPGK GLEWSTINS DGGYTTYADS VKGRFTISRD NSKNTLYLQM NSLRAEDTAV
241	YYCAENVDCY GGYCYRANYW GQGTLVTVSS TSTTTPAPRP PTPAPTIASQ PLSLRPEACR
301	PAAGGAVHTR GLDFACDIYI WAPLAGTCGV LLLSLVITLY CKRGRKKLLY IFKQPFMRPV
361	QTTQEEDGCS CRFPEEEEGG CELRVKFSRS ADAPAYQQGQ NQLYNELNLG RREEYDVLDK
421	RRGRDPEMGG KPRRKNPQEG LYNELQKDKM AEAYSEIGMK GERRRGKGHD GLYQGLSTAT
481	KDTYDALHMQ ALPPR

完整核酸序列见同目录 37HVPX_D12_vector_sense_4580bp.fasta（载体正义方向）与 CAR_orf_1488nt.fasta。