

Sanger 测序数据质控取证报告

样品 DAPA21 · dapA 缺失位点验证

项目	内容
文件名	DAPA21_TSM20260319057101751_202603190571BAN171_E08.1_1.ab1
测序服务商	擎科生物 TSINGKE (头文件 RGNm1 = TSINGKE)
仪器 / 耗材	ABI 3730xl · POP7 聚合物 · BigDye Terminator v3 · KB 1.4.1.8
运行信息	2026-03-20 20:03:14 · 泳道 8 · 96 孔板 E08
报告读长	735 bp

结论一：这份 .ab1 的色谱图是合成的，不是真实电泳信号。

7 项独立检验全部异常；文件内的「原始道」还属于另一份 2023 年的哺乳动物载体样品。该文件不能作为克隆验证凭证使用。

结论二：报告的 735 bp 序列本身是真实生物学序列，内容为 dapA 无痕敲除的连接点。

缺失 878 bp (占 dapA CDS 的 99.9%)，邻近的 bamC / gcvR / purC 完好，无 FRT / loxP / 抗性盒残留。侧翼序列 100% 匹配 BL21 与 K-12 MG1655 (与 Nissle 1917 差 7 处)，故背景为 BL21 / K-12 而非 EcN。

结论速览

问题	结论
这份 .ab1 合理吗？	不合理。色谱图为合成/重绘，7 项检验全部异常。
判读序列可信吗？	序列内容像是真实的 (完美比对到 E. coli)，但该文件无法为它提供任何证据支持。
序列是什么？	Δ dapA 无痕缺失连接点，跨 gcvR bamC 断点。
菌株背景？	侧翼 100% 匹配 BL21 与 K-12 MG1655，与 Nissle 1917 差 7 处 —— 不是 EcN 背景。
缺失多大？	878 bp，占 dapA CDS 的 99.9%，无标记、无疤痕。
原始道是什么？	一条完全不相关的哺乳动物慢病毒载体 (pCDH-CMV-MCS-EF1-Puro 类骨架的 EF1 α 启动子区)。

本报告结构


一	真实性取证：7 项检验 + 元数据矛盾 + 波形对比图
二	文件内含三条互不相关的序列：比对统计与 BLAST 鉴定
三	序列的具体生物学分析：dapA 断点定位、位点示意图、解读与建议
附录	方法与脚本清单；报告的 735 bp 序列原文

一、真实性取证：为什么判定色谱图是合成的

真实的毛细管电泳数据必然带有几项物理特征：峰高随迁移时间指数衰减、峰形因扩散与拖尾而不对称、峰间距随读长漂移、基线经扣除后有正负涨落、读段两端质量值下降。合成或重绘的色谱图不具备这些性质。以下 7 项检验相互独立。

#	检验项	本文件实测	真实数据应有
T1	峰间距一致性	标准差 0.000 scan (恒为 13)	随读长单调漂移，sd > 1
T2	分析道长度	9555 = 735 × 13，整除	与碱基数无整除关系
T3	峰高分布	CV = 0.003；首 50 峰 / 末 50 峰 = 1.00；735 个峰仅 11 种高度	CV 0.3–0.8；末端衰减数倍
T4	峰形对称性	峰心等距两点强度差 0.0057（近乎完美高斯）	> 0.03（毛细管拖尾）
T5	基线特征	51.2% 的点恰好等于 0，零个负值	扣基线后必然出现正负涨落
T6	质量值 QV	735 个碱基全部 QV = 50，唯一取值 1 个	读段两端必然衰减
T7	内部数组自洽	PBAS/PCON/PLOC = 735，而 P1AM/P2AM/P2BA/P1WD = 252	全部相等

检验代码见 01_ab1_qc_forensics.py，原始输出见附带的 qc_forensics_report.txt。



元数据自相矛盾

头部 RUND = 2026-03-20（与订单号 TSM2026031905710175 一致），但同一文件里：

字段	取值	含义
RunN1	Run_ABI-PC_2023-03-13_20-03_0179	运行名仍是 2023 年
BCTS1	2023-03-13 21:38:20 +08:00	采集时间戳 2023 年
CTID1 / CTNM1	20230313-FY041-020-020-f	容器 ID 2023 年
SMED1	Jan 01, 2023	样品制备日期 2023 年
TUBE1	E2	与文件名标注的 E08 孔不符

这些残留说明：该文件是以一份 2023 年的旧 .ab1 为模板重写生成的，而不是仪器直接输出。

二、文件内含三条互不相关的序列

原始道（DATA1-4）是文件中唯一未被改写的部分。对它做基线扣除，由数据自估 4×4 染料串扰矩阵后求逆解混，再逐通道寻峰，可独立反演出一条 898 nt 序列（因缺少 .mob 迁移率校正，约 10% 误差，足够做同源判定）。把它与文件内各序列做局部比对，并以 30 次序列随机打乱作对照：

比较对象	局部比对分	打乱对照	Z 值
原始道反演 vs 自身前 300 nt（阳性对照）	600	20 ± 2	+262.8
原始道反演 vs PBAS1 判读序列	24	21 ± 2	+1.3
原始道反演 vs P2BA1 内嵌 252 nt	19	19 ± 1	-0.2
PBAS1 vs P2BA1	20	19 ± 2	+0.3

即：原始波形与所报告的序列毫无关系，比对分与随机打乱无异。

BLAST 鉴定（NCBI nt / nr）

序列	最佳命中	一致性
PBAS1（735 bp，报告序列）	Escherichia coli Nissle 1917 染色体 CP171242.1	728/735 = 99.05% E = 0
原始道反演（898 nt）	慢病毒/哺乳表达载体 pCDH-CMV-MCS-lox-EF1-Puro-lox、pLV、pFUSE、piggyBac 等同源骨架	505/564 = 90%
P2BA1（252 nt）	无显著同源（符合「次选碱基」本应是噪音的性质）	—

原始道对应的是 2023 年那份模板文件里的哺乳动物载体样品；判读序列则另有来源。

三、序列的具体生物学分析：dapA 无痕敲除

把 PBAS1 反向互补后比对到 E. coli K-12 MG1655 (NC_000913.3)。该位点野生型基因顺序为 purC – bamC(nlpB/dapX) – dapA – gcvR（均在负链）。读段呈两臂分裂：

读段片段	对应 MG1655 坐标	比对分
右臂（bamC 侧）读段 1–365	2,598,517 – 2,598,881	730
左臂（gcvR 侧）读段 365–735	2,599,760 – 2,600,130	742

两臂在读段上重叠 1 bp（微同源“T”）。由此定出：

缺失区间 = MG1655 2,598,882 – 2,599,759 = 878 bp
占 dapA CDS (2,598,882–2,599,760 , 879 bp) 的 99.9%；bamC、gcvR、purC 无一碱基落入缺失区。

基因	MG1655 坐标	长度	落入缺失区
purC	2,596,905 – 2,597,618	714 bp	0 bp (0%)
bamC (nlpB/dapX)	2,597,831 – 2,598,865	1035 bp	0 bp (0%)
dapA	2,598,882 – 2,599,760	879 bp	878 bp (99.9%)
gcvR	2,599,906 – 2,600,478	573 bp	0 bp (0%)




图 2 位点示意。上行为野生型真实坐标；下行按缺失折叠绘制，即 gcvR 一侧整体左移 878 bp 与 bamC 侧直接相接——这才是样品分子的真实构型。735 bp 读段跨断点连续覆盖。

断点邻近序列

小写 = bamC 侧 | 竖线 = 连接点 | 大写 = gcvR 侧

...aggcgcgacttttgaacagagtaagccatcaaatctccctaaact | GGGCCATCCTCTGTGCAACAAGTGTCTCAATGGTACGTTTGGTA...

解读

1	dapA 被完整敲除。878/879 bp 被删除，只余起始密码子的 1 个碱基，无残留可读框。
2	无痕（markerless）敲除。连接处只有 1 bp 微同源，没有 FRT(34 bp)、loxP(34 bp) 或任何抗性表达盒——符合 λ -Red + FLP/I-SceI 无痕或 CRISPR 辅助的无标记缺失策略。
3	邻近基因完好。读段覆盖的 bamC 前 116 个密码子翻译后与参考 BamC 蛋白 116/116 = 100% 一致（MAYSVQKSRLAKVAGVSLVLLLAACSSDSRYKRQ…，含典型脂蛋白 lipobox “LAAC”）；该段对野生型 E. coli 基因组为 365/365 = 100%。gcvR 侧同样完整。说明缺失精确，未波及 BAM 外膜蛋白装配复合体组分与甘氨酸裂解系统调控子。
4	表型含义。dapA 编码 4-羟基-四氢吡啶二羧酸合酶（DHDPS），是赖氨酸 / DAP 支路第一个限速步骤。 Δ dapA 无法合成 meso-DAP，肽聚糖无法交联，离开外源 DAP 即裂解死亡——这正是活菌药物 / 接合供体菌标准的营养缺陷型生物封闭（biocontainment）设计。
5	菌株背景是 BL21 / K-12，不是 EcN。把两臂分开比对（避开断点）：bamC 臂对 BL21 与 MG1655 均 365/365 = 100%，gcvR 臂均 371/371 = 100%；对 Nissle 1917 则分别是 362/365 与 367/371（共 7 处差异）。该位点 BL21 与 K-12 序列相同，故只能排除 EcN，不能区分这两者。
6	唯一含此断点的已发表基因组。GenBank CP171242.1（“E. coli Nissle 1917”，2024 年提交）在同一位点同样缺失 dapA，读段对它 735/735 全长比对 99.05%——这是全长唯一能比上的基因组，但那 7 处差异说明它只是碰巧含同一连接点（两边都按“精确删掉 dapA CDS”设计，自然产生同一断点），并非本样品的背景。
7	文件名中的“DAPA21”与此完全自洽——很可能是 dapA 敲除克隆 #21 的验证测序。

建议

1	向擎科索要真实原始 .ab1，并说明本文件色谱图为合成、且原始道属于另一份 2023 年的哺乳载体样品。在拿到真实数据前，这份文件不能进实验记录、不能作为克隆验证凭证，更不能用于报批或论文补充材料。
2	拿到新文件后先跑 01_ab1_qc_forensics.py 复核。
3	dapA 敲除的关键结论（878 bp 无痕缺失、两侧基因完整）本身很可能是对的，但需要真实色谱图 + 双向测序（正反向引物各一条，完整覆盖断点）来确认。
4	补做表型验证：无 DAP 的 M9 / LB 平板上不生长、补加 DAP（50–100 μ g/mL）恢复生长。

附录 A 方法

脚本	作用
01_ab1_qc_forensics.py	解析 ABIF 头部与数据块；常规 QC（读长 / QV / 信噪比 / 简并碱基）；7 项合成痕迹检验
02_raw_trace_basecall.py	对原始道滑动分位数扣基线；按主导通道聚类自估染料串扰矩阵；求逆解混后逐通道寻峰反演序列
03_dapA_junction.py	两臂分别做局部比对定位；求断点、微同源与缺失区间；计算各基因落入缺失区的比例
04_report_figures.py	生成图 1、图 2
05_build_pdf_report.py	生成本报告

依赖：biopython · numpy · matplotlib · reportlab；03 需联网访问 NCBI E-utilities。比对使用 Biopython PairwiseAligner（local，match +2 / mismatch -3 / gap -10,-4）；同源鉴定使用 NCBI BLAST URL API（megablast 对 nt、blastx 对 nr）。

附录 B 报告的 735 bp 序列

文件内 PBAS1 字段原文（FASTA 见 DAPA21_reported_read.fasta）：

1	CAGTTCGGCA CCTTCAACG GTAACGTTGA TTCAATCAGA GTAATGGCAT TCCATGAACC
61	GGAAAGCAGC ATAATAAACG TGAAGCTCTTC TCCCAGCATC GCCAGGCGAC TGTCTTCAAT
121	ATTACAGCCG CAACTACTGA CATGACGGGT GATGGTGTTT ACAATTCCAG GGCATCGGC
181	ACCCAACGCA GTGATACCA GATAATGTTG CGATGACAGT GTCAAAGTGG TTATTCCTTT
241	AAGGGGTGAG TTGTTCTTAA GGAAAGCATA AAAAAACAT GCATACAACA ATCAGAACGG
301	TTCTGTCTGC TTGCTTTTAA TGCCATACCA AACGTACCAT TGAGACACTT GTTTGCACAG
361	AGGATGGCCC AGTTTAGGGA GATTTGATGG CTTACTCTGT TCAAAAGTCG CGCCTGGCAA
421	AGGTTGCGGG TGTTCGCTT GTTTTATTAC TCGCTGCCTG TAGTTCTGAC TCACGCTATA
481	AGCGTCAGGT CAGTGGTGAT GAAGCCTACC TGGAAGCGGC ACCGCTTGCG GAGCTTCATG
541	CCCCGGCTGG AATGATTTTG CCGGTGACCT CCGGTGATTA TGCAATCCCG GTGACCAACG
601	GTAGTGGTGC TGTCGGTAAG GCCTGGACA TTCGTCCACC AGCCAGCCG CTGGCACTGG
661	TTTCTGGCGC GCGTACCCAG TTCACGGGCG ATACCGCTTC ATTGCTGGTG GAAAATGGTC
721	GTGGCAATAC TCTGT

说明：本报告所有数值均由附带脚本对该 .ab1 文件直接计算得出，可复现。序列同源判定依赖 NCBI 公共数据库 2026-08 版本。